

县域生活信息交换服务平台

需求明细 + 低保真页面设计 (v0.1 评审稿)

2026-09-01

○、免责声明与阅读须知

本文档为产品需求与技术方案的**技术性建议稿**，不构成法律、合规、财务或投资建议。

1. 本文档中涉及的资质要求、备案流程、内容审核义务、个人信息保护要求、劳务与用工关系认定、资金结算与支付合规等内容，仅为基于公开常识的一般性提示。平台正式上线前，**必须由持牌律师、当地网信/市场监管主管部门、以及支付/结算合作机构逐项确认**，不得以本文档作为合规依据。
2. 文档中的性能数字（QPS、延迟、成本、并发承载量等）均为**工程估算量级**，用于容量规划参考，不构成任何性能承诺。真实数值必须以压测结果为准。
3. 文档中提到的第三方服务、开源组件、模型名称仅作技术选型举例，不代表推荐或商业背书，其许可协议、数据出境政策、价格与可用性以各服务商官方条款为准。
4. 平台定位为**信息交换与撮合服务**，不介入交易、不提供资金担保、不承担交易结果责任。该定位是产品设计的核心前提，任何偏离都会实质改变平台的法律责任边界，需重新做合规评估。
5. 本文档不含真实用户数据。所有姓名、电话、村镇名称、价格均为示例占位。
给评审者的提示：文档第六章（可扩展性预留）和第七章（性能优化）是本方案的核心价值；如果时间有限，优先评审这两章，加第九章线框图。

一、产品定位与业务边界

1.1 一句话定位

一个县域范围内、以语音和一键发布为主要输入方式的本地生活信息撮合平台：把“谁有什么、谁要什么、谁想约谁”这三件事，用最低的操作门槛沉淀成结构化信息，再用 AI 做匹配和分发。

1.2 为什么是县域

县域市场有三个和一线城市完全不同的特征，这决定了产品形态：

- **信息极度不透明但地理极度集中。**同一个乡镇内，谁家有闲置农机、谁家缺短工，全靠熟人口耳相传；一旦上了平台，撮合半径小、履约成本低、见面即可验货，**天然不需要资金担保就能成交**。这是“不做资金托管”这一决策的 business 基础，不是技术妥协。
- **用户打字能力弱、方言重、年龄偏大。**所以语音必须是一等输入方式，不是可选项。

- **单县用户总量有天花板**（常住人口通常 30-80 万，活跃用户天花板量级在数万），**这恰恰是低配服务器和小模型可行的前提**——不需要为百万并发做设计。

1.3 业务范围（首期全部纳入 MVP）

用户在首期确认四个模块**全部进入 MVP**，因此本文档对四者均出详细需求与页面：

模块

助农供求
求职招工 + 有偿任务
二手市场（逛一逛）
约局互动

四个模块**共用同一套底层信息模型**（见 3.5 节统一 Post 模型），这是首期能同时上线四个模块而不至于工作量翻四倍的关键设计。

1.4 明确不做的事（边界，需求评审时请重点确认）

以下每一条都是**主动放弃**，写进文档以防后续需求蔓延：

- **不做资金托管、不做担保交易、不做平台代收代付**。首期无任何资金流经平台账户。
- **不做物流履约**，不接快递/同城配送。
- **不做实名强认证**（仅手机号 + 可选微信昵称），但保留实名接口位。
- **不做信用分体系**，仅做举报与封禁。信用分需要交易闭环数据支撑，首期没有。
- **不做内容社区**（无关注、无点赞、无信息流推荐算法），避免变成内容平台而承担更重的内容审核义务。
- **不做跨县扩张**，首期单县单实例，跨县在第三阶段以多租户方式解决。

1.5 成功指标（MVP 阶段，3 个月）

指标

发布转化率
语音发布占比
首次响应率
次周留存
单条信息服务端成本

首次响应率是本产品的北极星指标。发布量再高，如果发布后没人搭话，用户就不会再来。第七章所有的 AI 和 RAG 优化，最终都服务于这一个指标。

二、用户与角色

2.1 用户画像

画像 A — 种植户 / 养殖户（45-65 岁，男性居多）：手机是千元安卓机，微信重度使用，打字慢或不会打字，语音消息是主要沟通方式。核心诉求是“我的货怎么卖出去、卖得比收购商价高一点”。对价格敏感，对复杂界面零容忍。**设计约束：字号大、按钮大、语音优先、流程不超过三步。**

画像 B — 返乡/在县青壮年（20-40 岁）：会用抖音和闲鱼，打字无障碍。诉求是找活干（日结零工、跑腿）、买卖闲置、周末约局。**设计约束：要有可逛的信息流，否则留不住。**

画像 C — 小微雇主 / 商户 / 包工头（30-55 岁）：需要临时找人（装卸、采摘、装修打杂），诉求是“今天下午要 5 个人”。高频、急、愿意重复使用。**这是最容易形成付费意愿的人群，收费扩展点主要瞄准他们。**

画像 D — 信息中间人 / 村级信息员：本地能人，帮别人代发信息，天然的种子用户和内容供给方。**设计约束：需要“代发”能力和多条信息管理能力。**

2.2 角色与权限矩阵

能力

浏览列表与详情

查看联系方式

发布信息

语音发布

代他人发布

站内私聊

举报

置顶/加急（收费预留）

审核、下架、封禁

= 功能位与数据结构在首期即建好，开关关闭，见 6.2 节。

游客可浏览但看不到联系方式，这是最有效的注册转化钩子，也是防爬取联系方式的第一道闸。

三、总体架构（四位一体组合体）


3.1 产品组合体：一套后端，四个门面

平台不是“一个小程序”，而是**四个承载体共用一套后端与一套数据**的组合体。四者分工明确，互相导流，不重复建设。

承载体

公众号
小程序
后台管理端
AI Agent

组合体关系图



###

三条组合体设计铁律

- 1. **AI Agent 是入口，不是模块**。它嵌在小程序首页顶部（不是底部 Tab 的第五个），并作为公众号自定义菜单的一级项。用户不需要知道“AI 在哪”，只需要知道“有事就在这里说一句”。详见第八章。
- 2. **公众号的每一次推送都必须落到一条可交互的信息上**。纯资讯推送在县域的打开率会快速衰减；每篇图文底部必须挂“本周镇上最新 5 条供求/招工”，这才是召回的真实抓手（见 4.11）。
- 3. **后台管理端与 C 端共用同一份 post 表和状态机**，不做数据同步、不做双写。管理端只是同一份数据的另一个视图 + 一组带权限的写操作（见 4.12）。

3.2 端侧策略

用户选定**双端同构**。落地方式不是“一套 H5 两处套壳”这么简单，需要明确分工，否则语音链路会出问题：

层


UI 渲染
业务逻辑
录音

定位
登录
消息触达
支付（预留）

建议：用 uni-app 或 Taro 做同构，把上述差异全部收敛到一个 platform-adapter 层，业务代码只调用 adapter.record() / adapter.login()。这一层是双端同构成本可控的唯一保障，必须在写第一个业务页面之前先写完。

小程序为主、公众号为辅：公众号承担“内容触达 + 拉新 + 兜底浏览”，小程序承担完整交互。原因是录音和支付在小程序里体验和稳定性显著更好，而公众号的群发能力在县域的传播效率更高。

3.3 系统分层



系统分层架构图

(系统分层在组合体图下半部分展示) **关键设计：**所有 AI 能力调用必须经过 AI 编排层，业务代码不允许直接调用任何模型 SDK。这是 6.3 节“迁移窗口”的全部基础。

3.4 技术选型建议（面向低配服务器）

层

后端语言
数据库
缓存
队列
向量检索
对象存储

部署

一句话原则：能少一个组件就少一个组件。 2C4G 的机器上，每多一个常驻进程就少一份可用于页面缓存的内存。

3.5 统一信息模型（★ 全文最重要的设计）

四个业务模块**不建四套表**，而是共用一张 post 主表 + 一个 JSON 扩展字段：

```
post
├── id, author_id, category(枚举), sub_category
├── title, body_text          ← 结构化后的正文
├── raw_voice_url, raw_asr_text ← 原始语音与转写，永久保留（★见 7.4）
├── price, price_unit, quantity, quantity_unit
├── location_code(县/镇/村三级), lng, lat
├── contact_type, contact_value ← 需权限才可见
├── status(草稿/待审/已发布/已成交/过期/下架)
├── valid_until              ← 到期自动下架（★关键，见下）
├── ext JSON                 ← 各类目差异字段
├── quality_score            ← 信息完整度打分，用于排序
├── created_at, updated_at, bumped_at
```

ext 字段按类目存差异化内容：

类目

助农供求

求职招工

有偿任务

二手

约局

这个设计带来三个直接好处：

1. 四个模块共用同一套列表页、详情页、发布页、搜索、审核后台，**开发量从 4× 降到约 1.5×**。
2. 新增类目（比如后期加“房屋租售”“寻人寻物”）只需加枚举 + ext 模板 + 表单配置，**零后端改动**。
3. AI 抽取的输出目标统一为这一个 schema，**Prompt 只需一套 + 类目差异片段**，小模型也能稳定输出（见 7.3）。

valid_until 到期自动下架是县域场景的刚需：农产品有上市窗口、零工是“今天下午”、约局是“周六”。过期信息不清理，列表会迅速被垃圾填满，**这是同类平台最常见的死法**。默认有效期按类目设定（**零工/有偿任务 2 天、约局到活动日、助农供求 7 天、二手 15 天**），到期前 4 小时推送“是否还有效”一键续期。缩短过期时间换取列表时效性，这是县域场景的正确权衡。

四、功能需求明细

需求编号规则：FR-**<模块>**-**<序号>**。优先级 P0 = MVP 必须，P1 = MVP 尽量，P2 = 二期。

4.1 账号与身份

编号

- FR-ACC-01
- FR-ACC-02
- FR-ACC-03
- FR-ACC-04
- FR-ACC-05
- FR-ACC-06
- FR-ACC-07

实名认证的合规与溯源价值：违规信息（诈骗、传销、非法用工）必须可追溯到自然人，这是平台免责的法律前提。身份证号后六位 + 手机号双因素验证，既满足溯源要求，又不至于吓退用户（相比上传身份证正反面照）。

限额机制防刷屏与批量采集：县域平台最大的内容污染来自同一用户反复发布相同信息，以及黑产批量抓取联系方式。限额 + 举报奖励形成正向循环。

4.2 位置与圈层

编号

- FR-LOC-01
- FR-LOC-02
- FR-LOC-03
- FR-LOC-04
- FR-LOC-05

用行政区划而不是 GPS 半径做主检索，理由有三：县域用户对“哪个镇”的理解远强于“5 公里内”；行政区划可以整型索引，MySQL 查询极快，不需要地理空间索引；GPS 授权拒绝率在中老年用户中很高。

4.3 语音能力（★ 核心差异化）

4.3.1 语音输入

编号

- FR-VOI-01
- FR-VOI-02
- FR-VOI-03
- FR-VOI-04

FR-VOI-05
FR-VOI-06
FR-VOI-07
FR-VOI-08

4.3.2 语音输出
编号

FR-VOI-08
FR-VOI-09

FR-VOI-09 是成本关键：一条热门信息可能被 500 人查看，缓存后 TTS 调用量从 500 次降到 1 次。

4.3.3 语音链路降级策略

ASR 是本产品最贵、最慢、最容易失败的一环。必须设计三级降级：

- 1. **正常：**云端 ASR，2-4 秒返回。
- 2. **繁忙/超时 (>8s)：**提示“识别慢了，先帮你把语音发出去，文字随后补上”—— **先以纯语音形态发布**，Worker 后台补转写。这条降级保证了发布流程永不卡死。
- 3. **ASR 服务不可用：**直接切纯语音发布 + 引导打字，界面不出现任何报错弹窗。

4.4 一键发布（★ 核心差异化）

4.4.1 主流程

目标：从点击“发布”到信息上线，语音路径 ≤ 3 次交互、总时长 ≤ 30 秒。

点发布 → 长按说话 → [AI 自动填表] → 瞄一眼 → 点“发布”
(一次) (0 次交互) (可改) (一次)

编号

FR-PUB-01
FR-PUB-02
FR-PUB-03
FR-PUB-04
FR-PUB-05
FR-PUB-06
FR-PUB-07
FR-PUB-08
FR-PUB-09
FR-PUB-10

FR-PUB-02 是本产品最反直觉但最重要的交互决策。 传统发布流程是“选类目 → 选子类目 → 填表单”，对画像 A 的用户这三步就已经流失一半。让 AI 承担分类工作，用户只管说话。分类准确率只要达到 85%，整体体验就远好于让用户自己选。

FR-PUB-10 直接对抗县域平台的头号内容问题：同一个人反复发几乎相同的信息刷屏。

4.4.2 信息有效期可配置（新增）

编号	需求	优先级
FR-PUB-11	后台管理端按类目配置默认有效期（见 FR-ADM-16）：零工/有偿任务 2 天、约局到活动日、助农供求 7 天、二手 15 天，运营可全局调整	P0
FR-PUB-12	发布时用户可自选有效期：下拉选项“2 天/7 天/15 天/30 天/自定义”，默认值从后台配置读取	P0
FR-PUB-13	到期前 4 小时推送“是否还有效”一键续期，续期后 valid_until 延长、bumped_at 刷新（见 FR-MINE-02）	P0
FR-PUB-14	自定义有效期支持日期选择器（最长不超过 90 天），约局场景可精确到活动结束时刻	P1

设计理由：不同类目时效性差异巨大。零工“今天下午缺人”和二手家电“不着急卖”的有效期不应该一样。后台可配置保证灵活性，用户可自选保证体验。到期自动下架是保持列表时效性的关键机制（见 3.5 节 valid_until 字段说明）。

4.4.3 一键发布的性能设计

发布接口**必须同步返回、异步补全：**


阶段
语音上传
ASR 转写
字段抽取（LLM）
自动审核（见 4.4.4）
落库 + 上线
向量化入索引

语音走 OSS 直传是低配服务器的生死线：60 秒语音约 120KB，若经应用服务器中转，20 个用户同时上传就会打满 2C 的带宽和连接数。

4.4.4 自动审核流程（★ 生存底线）

本平台采用先审后发 + 自动检测 + 人工复审的三级审核机制。这不是后期优化项，而是首期 MVP 必须完整实现的功能，否则平台一天都活不下去。

三级审核架构



审核需求明细

编号

- FR-AUDIT-01
- FR-AUDIT-02
- FR-AUDIT-03
- FR-AUDIT-04
- FR-AUDIT-05
- FR-AUDIT-06
- FR-AUDIT-07
- FR-AUDIT-08
- FR-AUDIT-09
- FR-AUDIT-10

FR-AUDIT-11
FR-AUDIT-12
FR-AUDIT-13

为什么必须先审后发

县域是熟人社会，一条诈骗信息的社会成本远高于一线城市：

- 受骗者会告诉全村“那个平台是骗子平台”，口碑瞬间崩塌。
- 平台可能被认定为“明知存在违法信息而未采取措施”，承担连带责任。
- 内容安全事故（涉黄涉政）会直接导致小程序/公众号被封，无申诉余地。

先发后审在县域场景下是自杀行为。自动审核的目标是让 90% 的正常信息秒级通过，10% 的可疑信息进人工队列，用户体感是“点了发布，3 秒后就能在列表看到”，这已经足够快。

涉敏场景特殊处理

以下场景**触发强制人工审核**，不走自动通过（根据你最新要求补充）：

触发条件

信息包含金额字段（price > 1000 元）
文本提及“证件”“身份证”“营业执照”
文本提及“医疗”“看病”“药”“偏方”
文本提及“法律咨询”“律师”“代办”
文本提及“理财”“投资”“股票”“期货”
文本提及“高空”“登高”“起重”“电工”

这些关键词匹配后，信息状态直接置为“待审”，**不影响发布体验**（用户看到“发布成功，审核中”），但必须人工过一遍再上线。

审核成本估算

项

云端图片审核
文本审核（敏感词）
人工审核
合计

单县每日审核成本约 100 元，这是必须支付的“生存税”，不可省略。

4.5 逛一逛（闲鱼式浏览）

编号

FR-BRW-01
FR-BRW-02

FR-BRW-03

FR-BRW-04

FR-BRW-05

FR-BRW-06

FR-BRW-07

FR-BRW-08

FR-BRW-03 的排序公式故意不做个性化推荐：个性化需要用户行为数据 + 实时计算，在低配服务器上 是灾难，而且县域信息总量小，“距离 + 新 + 完整”三个因子已经足够好。

FR-BRW-08 是最高性价比的性能优化：首页是 80% 的请求来源，缓存 60 秒意味着数据库 QPS 从数百降到个位数。县域场景下 60 秒的信息延迟完全可接受。

游标分页 (WHERE bumped_at < ?) 而不是 OFFSET：OFFSET 1000 在 MySQL 上会扫描前 1000 行，深翻页时会明显变慢。

4.6 搜索

编号

FR-SCH-01

FR-SCH-02

FR-SCH-03

FR-SCH-04

FR-SCH-05

FR-SCH-06

FR-SCH-03 不引入 Elasticsearch 是刻意的：ES 单节点至少吃 1-2GB 内存，在 2C4G 机器上会直接挤爆。MySQL 的 ngram 全文索引在百万行级别、单县词汇量有限的场景下完全够用。真要升级，第三阶段换 Meilisearch（内存占用约为 ES 的 1/5）而不是 ES。

FR-SCH-04 把搜索失败转化为内容生产——用户找不到就让他发求购，这是双边平台冷启动最有效的技巧之一。

4.7 AI 对话界面

4.7.1 定位

AI 对话**不是通用聊天机器人**，而是“会说话的信息检索与发布入口”。它只做四件事：

1. **找信息**：“有没有人收玉米”“镇上有没有日结的活”
2. **帮发布**：“我要卖 200 斤土鸡蛋”→ 走一键发布流程
3. **问平台规则**：“怎么举报”“为什么我的信息被下架了”
4. **防诈骗答疑**：“他让我先付定金，这靠谱吗”→ 触发反诈提示（见 5.2）

编号

FR-AI-01

FR-AI-02
FR-AI-03
FR-AI-04
FR-AI-05
FR-AI-06
FR-AI-07
FR-AI-08

FR-AI-03 是产品原则：AI 用自然语言复述信息会引入幻觉风险（把 3 元说成 5 元），而信息卡片直接来自数据库，永不失真。**AI 负责理解意图和排序，不负责陈述事实。**

FR-AI-05 的拒答边界必须硬。用户会问天气、问农业技术、问法律问题。一律引导回平台能力范围，理由：小模型在这些领域答错的概率高，而错误的农技/用药建议可能造成真实损失。

4.7.2 AI 意图路由（★ 小模型性能核心）

不是每句话都要过大模型。 三级路由：

层级

- L0 规则/正则
- L1 小模型/嵌入
- L2 大模型

这个路由把大模型调用量压到 10-20%，是“用差模型也能跑得动”的第一支柱。具体实现见 7.3。

4.8 四大业务模块的差异化需求

四模块共用列表/详情/发布骨架，以下只列**必须差异化**的部分。

4.8.1 助农供求

编号

FR-AGR-01
FR-AGR-02
FR-AGR-03
FR-AGR-04
FR-AGR-05
FR-AGR-06
FR-AGR-07

FR-AGR-05 的品种词库是本模块 AI 效果的关键。“沙糖桔”“砂糖橘”“糖桔”是同一个东西，靠模型自己归一不可靠，靠人工维护的 200 词映射表则接近 100% 准确，且零成本。**这是“用规则弥补小模型能力”的典型案列。**

FR-AGR-07 的海报分享是县域最有效的传播方式，微信群转发的转化率远高于站内推荐。

4.8.2 求职招工 + 有偿任务

编号

- FR-JOB-01
- FR-JOB-02
- FR-JOB-03
- FR-JOB-04
- FR-JOB-05
- FR-JOB-06
- FR-JOB-07
- FR-JOB-08

FR-JOB-02 的三要素强校验是本模块唯一的强校验点。招工信息缺日薪就是无效信息，会浪费大量用户时间，这里牺牲一点发布顺畅度是值得的。

FR-JOB-07 用“行为可见”代替“信用评分”：不需要建模、不需要交易数据，只是把已有数据展示出来，成本近乎零，但对识别骗子中介很有效。

△ 合规提示：招工与有偿任务涉及劳务关系认定、工伤责任、劳务派遣资质等问题。平台仅作信息展示，但**必须在显著位置声明平台非用工方、非中介方**，且不得代为议定报酬或组织派工。此条须经律师确认，见第○章第 1 条。

4.8.3 二手市场（逛一逛）

编号

- FR-SEC-01
- FR-SEC-02
- FR-SEC-03
- FR-SEC-04
- FR-SEC-05
- FR-SEC-06

4.8.4 约局互动

编号

- FR-ACT-01
- FR-ACT-02
- FR-ACT-03
- FR-ACT-04
- FR-ACT-05
- FR-ACT-06

FR-ACT-07

FR-ACT-07 必须做硬拦截，不是软提示。“打牌”这个类目天然会吸引赌博信息，一旦被利用，平台面临的是刑事风险而非民事风险。建议措施：打牌类信息**默认不允许填写任何金额字段**，并在发布时强制勾选“本局不涉及赌博”。**此条须经律师确认。**

4.9 消息与私聊

编号

- FR-MSG-01
- FR-MSG-02
- FR-MSG-03
- FR-MSG-04
- FR-MSG-05
- FR-MSG-06

FR-MSG-02 的设计意图：站内私聊留下证据链，方便处理纠纷和识别诈骗；直接给电话则平台完全失去可见性。但**不强制**——县域用户习惯打电话，强制站内聊会流失用户。做法是把“在线聊”做成主按钮、“打电话”做成次按钮。

FR-MSG-01 首期用长轮询而非 WebSocket：WebSocket 在 2C4G 机器上维持数千长连接会吃掉大量内存，而县域私聊频率低。30 秒长轮询完全够用，且实现简单、无状态、便于水平扩展。

4.10 我的

编号

- FR-MINE-01
- FR-MINE-02
- FR-MINE-03
- FR-MINE-04
- FR-MINE-05
- FR-MINE-06

4.11 公众号：内容触达与用户召回

公众号不是“小程序的入口摆设”，它承担县域平台最难的一件事——**把沉默用户拉回来**。县域用户的使用是事件驱动的（要卖货了、要找人了才想起平台），中间可能沉默两周。公众号是唯一能主动敲门的通道。

4.11.1 五类内容与排期

内容类型	频次建议	内容来源	落地钩子（必须有）
本地资讯	每周 2 篇	运营编辑 + 转载本地政务号	文末挂“本周镇上最新供求 5 条”

活动通知	按需	运营发起（赶集日、农技培训、球赛）	一键跳小程序“约局/报名”页
政策内容	每月 1-2 篇	农业补贴、医保社保、惠农贷款	文末挂“政策问答，问问 AI”
招聘推送	每周 1 篇（周日晚）	系统自动聚合 本周招工信息	每条职位直达小程序详情页
用户召回	事件触发	系统自动	直达对应信息/会话
编号	需求	优先级	
FR-MP-01	自定义菜单三栏：① 发信息（跳小程序发布页）② 问问 AI（跳 AI 对话页）③ 逛一逛/帮助	P0	
FR-MP-02	关注后自动回复：一句话介绍 + 免责与反诈提示 + 小程序卡片	P0	
FR-MP-03	招聘周报自动生成 ：每周日 20:00 聚合本周 category=job 且未过期的信息，套用图文模板自动排版，运营一键确认后群发	P0	
FR-MP-04	图文模板统一含“平台只做信息交流，不担保资金”页脚（与 5.4 一致）	P0	
FR-MP-05	用户召回推送（模板消息/订阅消息）触发条件见 4.11.2	P0	
FR-MP-06	关键词自动回复：用户直接在公众号发消息（含语音）→ 转 AI Agent 应答，48h 客服窗口内可多轮	P1	
FR-MP-07	渠道二维码（按乡镇/村分发），统计各乡镇拉新来源，用于 4.12 乡镇运营	P1	
FR-MP-08	群发前置合规检查：涉及价格、招工薪资的内容自动加“信息由用户提供，平台未核实”	P0	

4.11.2 召回触发规则（避免变成骚扰）

触发场景

你发的信息有人联系了

你发的信息即将过期
有新信息匹配你的历史需求
你报名的局要开始了
沉默 14 天以上

总频控：单用户每周主动推送 ≤ 3 条（交易类实时通知不计入）。县域用户对骚扰的容忍度低，取关一次就基本不会回来。宁可少推。

4.11.3 公众号与小程序的能力落差（务必在评审时确认）

公众号 H5 端的录音受 JSSDK 限制（需授权、单条上限 60 秒、部分机型不稳定），因此**公众号内不承载语音发布主流程**：点“发信息”一律跳小程序。公众号只保留“文字/语音提问 AI”这一条轻链路。这是刻意的能力收敛，避免在弱链路上做重功能。

4.12 后台管理端：审核、治理与运营

管理端是 Web 端（PC 浏览器），与 C 端共用同一份数据。**首期不追求功能齐全，追求“一个人能在 30 分钟内处理完一天的审核与投诉”。**

4.12.1 功能域一览

功能域

- 审核
- 投诉与举报
- 账号治理
- 分类管理
- 乡镇运营
- 数据统计

4.12.2 需求明细

编号	需求	优先级
FR-ADM-01	待审队列：按 AI 风险分倒序排列，高风险置顶， 不按时间排序	P0
FR-ADM-02	队列项一屏内展示全部判断依据：原文、ASR 原声（可播放）、AI 抽取结果、命中的风险词、发布者历史	P0
FR-ADM-03	三键处置：通过 / 修改后通过 / 驳回（带预设驳回理由，一键发通知）	P0
FR-ADM-04	批量通过（低风险分 + 同类目，勾选后一次提交）	P0
FR-ADM-05	审核操作全量留痕（操作	P0

	人、时间、前后值），不可删除	
FR-ADM-06	举报工单列表：按“同一对象被举报次数”聚合，避免重复处理	P0
FR-ADM-07	一键“下架 + 封禁 + 通知所有联系过该信息的用户”（诈骗止损组合操作，见 FR-ANTI-18）	P0
FR-ADM-08	申诉复核入口：被封禁用户提交的申诉进独立队列，双人复核后可解封	P1
FR-ADM-09	涉刑事线索导出（会话记录 + 发布记录，带时间戳），供配合公安调取	P1
FR-ADM-10	用户检索：按昵称/手机号后四位/openid/发布内容关键词	P0
FR-ADM-11	封禁维度 openid + 手机号 + 设备号三选或全选，支持临时封禁（1/7/30 天）与永久	P0
FR-ADM-12	用户画像页：发布数、被举报数、被查看联系方式次数、投诉率	P1
FR-ADM-13	高危名单（黑名单手机号）导入/导出，与 FR-ANTI-15 联动	P1
FR-ADM-14	类目树可视化增删改（对应 3.5 节 category/sub_category 枚举）	P0
FR-ADM-15	ext 字段模板在线配置 ：新增类目只需配字段名、类型、是否必填、校验规则，前端表单自动生成，无需发版	P0
FR-ADM-16	按类目配置默认有效期 （valid_until 规则）与审核等级：在后台管理端全局配置，也可在发布时用户自选（见 4.4.4）	P0

FR-ADM-17	乡镇看板：分乡镇看发布量、响应率、活跃用户，找出“冷镇”	P0
FR-ADM-18	村级信息员管理：授予/回收代发权限，看其代发量与质量分	P1
FR-ADM-19	运营代发：管理端可代任意用户发布（必须留痕并在前台标注“信息员代发”）	P1
FR-ADM-20	人工置顶/加急（收费能力的手动版，先用人工验证需求，见 6.2）	P1
FR-ADM-21	核心指标看板：发布量、发布转化率、语音占比、 首次响应率 、次周留存（对齐 1.5）	P0
FR-ADM-22	AI 成本看板：ASR 时长、LLM token 数、单条信息成本，按日/周（对齐 7.8）	P0
FR-ADM-23	检索质量看板：搜索无结果率、AI 兜底率、意图路由分布（对齐 7.5(4)）	P1
FR-ADM-24	数据导出 CSV（脱敏，手机号默认掩码，导出行为留痕）	P1
FR-ADM-25	每日运营简报自动生成（待审量、举报量、异常指标），推送到运营微信	P2

4.12.3 管理端的两个设计取舍

取舍一：不做独立的权限系统。 首期角色只有三个（超管 / 审核员 / 乡镇运营），用简单的角色枚举 + 中间件校验，不引入 RBAC 框架。理由与 3.4 节一致——组件越少越好，2C4G 的机器不该跑一套权限服务。

取舍二：管理端不做前后端分离的重前端。 用服务端渲染或最简 SPA（如 Vue + Element Plus 单页），追求“能用、快、好改”。管理端每天访问的人不超过 5 个，为它做性能优化是资源错配。

安全提示：管理端必须独立域名/端口 + IP 白名单或 VPN 访问 + 强制双因素登录，**绝不与 C 端 API 共用同一公网入口**。管理端一旦被拖库，等于全县用户手机号泄露。这是本方案里安全等级最高的一处，不可省略。

五、防诈骗、内容治理与免责机制

这一章不是附属功能，而是本产品的生存条件。一个“不做资金担保”的信息平台，一旦出现几起典型诈骗案件，在县域这种熟人社会里口碑会瞬间崩塌，且平台可能被认定为未尽到合理注意义务。

5.1 县域场景的典型骗局清单

产品设计必须针对具体骗局，泛泛的“注意安全”没有任何作用。以下是需要重点防范的类型：

骗局类型

- 定金诈骗
- 高价收购骗前置费
- 招工押金/服装费
- 刷单兼职
- 二维码/链接钓鱼
- 虚假货源图片
- 冒充平台客服
- 赌博引流
- 借款/杀猪盘引流
- 农资假货

5.2 反诈功能需求（分层拦截）

反诈必须分布在用户路径的多个点上，单点提示会被无视。

第 1 层：发布时（源头）

编号

- FR-ANTI-01
- FR-ANTI-02
- FR-ANTI-03
- FR-ANTI-04
- FR-ANTI-05

第 2 层：浏览与详情时（认知）

编号

- FR-ANTI-06
- FR-ANTI-07
- FR-ANTI-08
- FR-ANTI-09

第 3 层：沟通时（临门一脚）

这是拦截成功率最高的一层，因为用户正处在要转账的决策点上。

编号	需求	优先级
FR-ANTI-10	私聊中出现“转账/定金/押金/扫码/验证码/银行卡/红包/先付/汇款”等词， 立即插入不可关闭的红色反诈卡片，置顶显示 5 秒 （“⚠ 平台从不要任何前置费用，先付款极易被骗！如已转账请立即报警”）	P0
FR-ANTI-11	首次与某人建立会话时，会话顶部展示一次性安全提示：“仅限平台内交易，转账需谨慎”	P0
FR-ANTI-12	检测到发送二维码图片时，弹出二次确认框：“陌生二维码可能是钓鱼，请线下当面交易”	P0
FR-ANTI-13	检测到冒充平台客服话术（“我是平台客服”“你的账号违规”“需要验证”），插入橙色警示卡：“平台客服只通过系统通知联系，绝不索要验证码或转账”	P0
FR-ANTI-14	会话工具栏常驻“防骗指南”快捷按钮，点击跳转反诈专页	P0

FR-ANTI-10 的实时拦截卡片是整个反诈体系的核心武器。它必须在聊天界面以最高优先级插入，用户滑走后 30 秒再自动弹回一次。县域诈骗案件 80% 发生在私聊转账环节，这一条能拦下大部分。

第 4 层：事后（处置与止损）

编号
FR-ANTI-14
FR-ANTI-15
FR-ANTI-16
FR-ANTI-17
FR-ANTI-18
FR-ANTI-19

FR-ANTI-18 是把损失控制在个位数的关键动作。诈骗者通常同时联系数十人，及时向其他潜在受害者预警，能阻止绝大部分未发生的损失。这个功能实现成本很低（一次批量推送），价值极高。

FR-ANTI-16 的“宁可误封”是明确的价值取向：在县域熟人社会里，一个诈骗案的口碑损害远大于一个被误封用户的抱怨，且误封可通过申诉快速恢复。

5.3 内容审核策略：先发后审 + 分级

内容情况

未命中任何风险词

命中低危词（联系方式外露、错别字类）

命中中危词（定金、押金、代理、加盟）

命中高危词（赌博、刷单、贷款、涉黄涉政、枪支药品）

图片机审不通过

为什么是先发后审：全量先审后发在县域场景下必然导致发布到上线延迟数小时，而零工信息“今天下午要人”，延迟等于信息失效。先发后审的风险用高危词硬拦截 + 快速下架能力 + 反诈分层提示来对冲。

△ **合规提示：**先发后审是否满足当地网信部门对信息服务的要求，**必须事先与主管部门沟通确认**。若被要求先审后发，则需配置人工审核值班（建议 7:00-22:00，非值班时段信息标记“待审”但允许发布者自己看到）。

5.4 平台免责声明（需展示在产品内的正式文本要点）

以下要点需由律师定稿后，展示在注册页勾选项、帮助中心、发布页折叠区三处：

1. 平台是**信息发布与展示的技术服务提供者**，不是交易参与方、不是中介方、不是用工方、不是保证人。
2. 平台**不对信息的真实性、准确性、合法性作出任何保证**，不对基于信息产生的交易结果、履约情况、货物质量、劳务纠纷承担责任。
3. 平台**不提供资金托管、不提供担保交易、不代收代付**，任何要求向平台账户付款的行为均为冒充。
4. 用户之间的交易与约定为**用户自主行为**，风险自担，建议当面验货、当面结算、保留凭证。
5. 平台有权对违规信息作下架、封禁处理，并**配合司法机关调取记录**。
6. 涉及农资、食品、药品、危险品、金融等特殊商品或服务，用户须自行确保具备相应资质，平台不承担审查义务但保留拦截权。
7. 约局类信息严禁涉及赌博、违法违规活动，一经发现即封禁并报告主管部门。

免责声明不能代替反诈措施。从实务角度，仅有免责声明而未采取合理技术措施的平台，仍可能被认定未尽到管理义务。5.2 节的分层拦截是免责声明能站得住的前提。

六、配置中心与可扩展性预留

6.0 配置化架构设计（★ 为后台管理预留完整能力）

本节解决的问题：文档中出现大量数值（“3 条/天”“7 天有效期”“1000 元触发人审”），这些数值首期可以硬编码，但**数据库表结构与代码架构必须按可配置设计**，否则后期每次调整都要改代码重新发版。

6.0.1 配置分类与存储策略

配置类型

业务规则

审核策略

消息模板

AI 参数

6.0.2 统一配置表结构

```
CREATE TABLE config (
  `key` VARCHAR(64) PRIMARY KEY COMMENT '配置项唯一键，如
user.daily_post_limit.normal',
  `value` TEXT COMMENT '配置值（支持JSON）',
  `type` ENUM('int','float','bool','string','json') COMMENT '值类型',
  `category` VARCHAR(32) COMMENT '分
类：account/post/audit/antifraud/ai/message/perf',
  `description` VARCHAR(255) COMMENT '配置说明（后台管理端显示）',
  `editable` BOOLEAN DEFAULT TRUE COMMENT '是否允许后台编辑',
  `min_value` INT COMMENT '最小值（type=int/float 时有效）',
  `max_value` INT COMMENT '最大值（type=int/float 时有效）',
  `updated_at` TIMESTAMP DEFAULT CURRENT_TIMESTAMP ON UPDATE
CURRENT_TIMESTAMP,
  `updated_by` INT COMMENT '最后修改人 admin_id',
  INDEX idx_category (category)
) ENGINE=InnoDB DEFAULT CHARSET=utf8mb4 COMMENT='全局配置表';
```

```
CREATE TABLE config_change_log (
  id BIGINT PRIMARY KEY AUTO_INCREMENT,
  config_key VARCHAR(64),
  old_value TEXT,
  new_value TEXT,
  admin_id INT,
  admin_name VARCHAR(64),
  ip VARCHAR(45),
  created_at TIMESTAMP DEFAULT CURRENT_TIMESTAMP,
  INDEX idx_key_time (config_key, created_at)
) ENGINE=InnoDB DEFAULT CHARSET=utf8mb4 COMMENT='配置变更日志（审
计溯源）';
```

6.0.3 代码层统一读取接口

禁止业务代码硬编码任何数值，必须通过 ConfigService 读取：

```
// 反例 (禁止)
if user.DailyPostCount >= 3 {
    return ErrLimitExceeded
}

// 正例
limit := configService.GetInt("user.daily_post_limit.normal")
if user.DailyPostCount >= limit {
    return ErrLimitExceeded
}
```

ConfigService 内部实现三层缓存：内存（启动时加载）→ Redis（TTL 300s）→ MySQL（兜底）。配置变更后主动清除 Redis，下次请求即读取新值，**无需重启服务**。

6.0.4 核心可配置项清单（67 项）

完整清单见独立文档 config_matrix.md，此处仅列关键类目：

类目

- 账号与权限
- 发布与有效期
- 审核规则
- 反诈拦截
- 浏览与搜索
- AI 参数
- 消息推送
- 性能与成本
- 合计

6.0.5 后台管理端配置页面（FR-ADM-16 扩展）

编号	需求	优先级
FR-ADM-16	系统配置页面：按 category 分 tab（账号/发布/审核/反诈/AI/消息/性能），每项显示当前值、可调范围、说明；保存前二次确认；保存后记录到 config_change_log	P0
FR-ADM-16-1	配置变更日志查询：谁在什么时候把什么从什么改成了什么	P0

FR-ADM-16-2	危险配置项（如审核开关、 限额大幅调整）需二次密码 确认	P1
FR-ADM-16-3	配置项支持“恢复默认值”一 键操作	P1

设计约束： - 所有改动**实时生效**（限额类）或定时生效（审核规则 60s 刷新），无需重启
- editable=false 的配置项（如 AI 提供商、数据库连接）在后台显示但不可编辑 - 每个数字框右侧显示可调范围（min_value ~ max_value），超范围禁止保存

6.0.6 首期实现清单

必须在 MVP 阶段完成（否则后期改造成本极高）： - config 表与 config_change log 表建好，初始数据全部入库 - ConfigService 封装完成，所有业务代码通过它读取配置 - 后台管理端“系统配置”页面基础版（可读可改，留操作日志）

可以延后到二期： - 配置变更审批流 - 配置版本管理与一键回滚 - 配置 A/B 测试能力

为什么这是“留后门”的正确姿势：不是事后打补丁，而是第一行代码就按可配置架构写。67 项配置中任何一项，后台运营想改时打开页面调一下数字就生效，而不是“联系技术改代码重新发版”。这才是真正的业务敏捷性。

6.1 收费能力与交易担保预留

原则：首期不实现，但把“缝”留好。判断标准是——将来启用某能力时，是否需要改动已有表结构或已有业务代码。如果需要，说明缝没留好。

6.1 资金担保的预留

首期无任何资金流。但要让将来“能接上”，需要现在就做三件事：

(1) 数据结构预留：引入 deal（交易意向）实体

即使不涉及资金，也从首期开始记录“撮合结果”：

```
deal
├── id, post_id, buyer_id, seller_id
├── state ← 见下方状态机
├── amount, currency          (首期为 NULL)
├── escrow_state              (首期恒为 NONE)
├── escrow_provider, escrow_ref (首期为 NULL)
├── created_at, closed_at
```

状态机（首期只用前 3 个状态）：

CONTACTED（已联系）→ AGREED（口头达成）→ CLOSED_OK / CLOSED_FAIL

└─[二期启用]→ ESCROW_HELD → DELIVERED
→ RELEASED / REFUNDED / DISPUTED

首期的用法：用户点“我联系了他”或私聊建立即产生 CONTACTED，成交后卖家点“已成交”则 CLOSED_OK。这批数据将来是担保交易的定价依据和风控依据，现在不收集，将来就是空白。

(2) 接口预留：抽象 PaymentProvider 与 EscrowProvider

```
interface EscrowProvider {  
    hold(dealId, amount) -> escrowRef  
    release(escrowRef) -> void  
    refund(escrowRef, reason) -> void  
    queryState(escrowRef) -> EscrowState  
}
```

首期实现一个 NoopEscrowProvider（所有方法抛“未启用”）。启用时新增一个实现类 + 改配置，业务代码零改动。

(3) 流程预留：详情页与订单页的按钮位

详情页保留一个隐藏的“担保交易”按钮位，订单流程页面骨架先搭（哪怕只有静态页）。UI 位置的预留比代码预留更容易被忽略，但改起来最贵。

△ 资金担保的合规前置条件（极重要）

一旦平台介入资金，法律性质根本改变：

- 平台代收代付资金可能构成**支付业务**，需支付业务许可证，或必须通过持牌机构（银行/持牌支付机构）的**分账/托管产品**实现。
- 自建资金池**几乎必然违规**，涉及非法集资、无证经营支付业务等风险。
- 正确路径是接入持牌机构的**担保支付/分账能力**（如微信支付的分账、服务商托管方案），平台只做指令发起方，不碰资金。

因此本文档的立场是：担保能力的预留只做技术侧，任何启用动作必须先完成持牌机构对接与法律意见书。此条须经律师与支付机构双重确认，见第○章。

6.2 收费能力的预留

首期全部免费，但收费点必须在数据结构上先存在，否则将来加收费会牵动整个 Post 排序逻辑。

预留的收费模型（不实现，只留位）

收费点

置顶 / 加急

会员（不限量发布 + 常驻曝光）

商家认证展示位

撮合成功佣金

AI 增值（智能询价、批量匹配推送）

技术预留清单

1. **post 表加 promotion 相关字段**：is_top、top_expire_at、weight_boost。排序公式**从首期就把 weight_boost 作为乘数因子写进去**（首期恒为 1.0）。这样启用置顶时不需要改排序 SQL。
2. **user 表加 member_level、member_expire_at**（首期恒为 0/NULL），配额检查函数从首期就读这两个字段。
3. **order 表 + PaymentProvider 接口**（同 6.1，共用支付抽象）。
4. **配额中心化**：所有“能不能发/能不能看”的判断收敛到一个 QuotaService。首期返回固定值，将来按会员等级返回不同值。**如果配额判断散落在各处 if 语句里，将来上会员体系就是全站返工。**
5. **功能开关（Feature Flag）**：payment.enabled、escrow.enabled、promotion.enabled、member.enabled 从首期存在，默认 false。

给运营的建议：置顶是最先该上的收费点，因为它对免费用户的体验伤害最小（只影响排序，不影响可见性），且雇主在“急着找人”时的付费意愿最强。**切忌首先对“查看联系方式”收费**——这会直接杀死双边平台的流动性。

6.3 服务器与模型的迁移窗口（★ 用户重点关注项）

目标：**从低配服务器 + 小模型升级到高配 + 大模型，业务代码零改动、可灰度、可回滚。**

(1) AI 能力网关（最关键的一层）

所有模型调用经过统一网关，业务侧只见到语义化接口：

```
interface AiGateway {
  classifyIntent(text)          -> Intent
  extractPostFields(text, category?) -> PostDraft
  embed(text)                  -> vector
  chat(messages, tools)        -> stream
  transcribe(audioUrl)         -> {text, confidence}
  synthesize(text)             -> audioUrl
  moderate(text | imageUrl)    -> RiskResult
}
```

网关内部通过配置决定路由到哪个后端：

```
ai:
  intent: { provider: local-rules-then-small, model: qwen-small }
  extract: { provider: cloud-a, model: <小模型>, fallback: cloud-b }
  embed: { provider: local, model: bge-small-zh, dim: 512 }
  chat: { provider: cloud-a, model: <小模型> }
  asr: { provider: cloud-asr-a, fallback: cloud-asr-b }
```

迁移动作 = 改一行配置。业务代码从不 import 任何模型 SDK。

(2) 迁移友好的三条硬规则

1. **向量维度不写死**：embedding 表存 dim 与 model_version，并允许多套向量共存。换嵌入模型时，新旧向量并行，双写 + 后台回填，切换后删旧。**这是换模型时最容易踩的坑——维度变了，历史向量全废，如果没有并行机制就必须停机重算。**
2. **保留全部原始输入**：raw_asr_text、raw_voice_url、用户编辑前后的 diff 全部留存。换更强的模型后，**可以用历史原始数据重跑抽取，把过去因小模型能力不足而缺失的字段补齐。**如果只存了结构化结果，这个升级红利就永久损失了。
3. **Prompt 与规则外置**：Prompt 模板、风险词库、同义词表、类目模板都放数据库或配置文件，带版本号，**不硬编码进代码**。换模型往往需要重调 Prompt，外置后无需发版。

(3) 服务器迁移的准备

措施

全部无状态化

文件全走 OSS

配置全走环境变量

Docker Compose – 可平移

数据库读写分离预留

定时全量备份 + binlog

读写分离的预留成本几乎为零，但事后补要改遍所有查询。首期就把 DAO 分开。

(4) 灰度与回滚

- AI 网关支持按用户 ID 哈希分流（如 5% 用户走新模型），对比 A/B 指标：抽取字段完整率、意图分类准确率、用户手动修改率。
- **用户手动修改率是最好的线上模型质量指标**：用户改得越少，说明抽取越准。这个指标零成本获得，且无需人工标注。
- 任何模型切换保留一键回滚配置。

七、性能优化：多维度分析

前提认知：低配服务器 + 小模型的组合下，性能不是靠优化代码解决的，而是靠**减少需要做的工作**。以下按“减少多少工作量”的降序排列。

7.1 容量估算与性能预算

以单县 5 万注册、5000 日活、峰值集中在早 7-9 点和晚 19-22 点估算：

指标

日请求量

峰值 QPS

其中首页/列表

发布量

语音时长
AI 对话轮次
图片流量

结论：2C4G 单机 + OSS/CDN 完全可以承载首期，前提是 7.2-7.7 的措施到位。 峰值 QPS 80 对 Go/Node 应用不是问题，真正的瓶颈在数据库连接、AI 调用排队、图片带宽三处。

以上均为工程估算量级，不构成性能承诺，须以压测为准（见第○章）。

7.2 业务层面的降载设计（性价比最高）

这一节的措施不需要任何技术难度，但能减少 70% 以上的负载。

措施

首页/列表服务端缓存 60s

信息到期自动下架

地域范围默认收窄到乡镇

不做个性化推荐

不做无限信息流

发布配额限制

AI 对话轮次上限

图片数量上限 6 张

热点信息 TTS/摘要缓存

“信息到期自动下架”值得再强调一次：它同时解决了内容质量、用户体验、检索性能、RAG 效果四个问题。一个能让数据集保持小而新的机制，比任何索引优化都有效。

7.3 AI 层面：让小模型也能稳定工作

小模型的问题不是“笨”，而是不稳定——同样的输入，有时输出合规 JSON，有时输出一段解释文字。工程上的应对不是换大模型，而是把任务切小、把格式约束死、把不确定性兜住。

(1) 三级意图路由（复用 4.7.2）

层级

L0 规则

L1 嵌入分类

L2 大模型

L1 用嵌入做分类而不是让 LLM 分类：嵌入调用成本约为生成调用的 1/50，延迟低一个数量级，且分类稳定性更高（无生成随机性）。

(2) 字段抽取：拆成“小而确定”的任务

反面做法：一次 Prompt 让模型输出包含 15 个字段的完整 JSON。小模型在这种任务上出错率很高，且一个字段错会导致整个 JSON 解析失败。

建议做法：

1. **先分类，再抽取。**知道是“招工”后，只需抽取该类目的 6-8 个字段，Prompt 更短、任务更窄。
2. **能用规则的绝不用模型：**
 - 价格、数量、日期、电话 → **正则 + 中文数字归一化**（“两百斤”“200 斤”“2 百斤”）。规则准确率接近 100%，模型反而会犯错。
 - 品种、工种、局类型 → **词库匹配**（见 FR-AGR-05）。
 - 地点 → 行政区划词库匹配。
 - **实测经验：这四类规则化后，需要模型处理的只剩“标题生成”和“正文清理”两件事。**
3. **强制结构化输出：**优先用支持 JSON Schema / Function Calling 的接口；若模型不支持，用极简格式（每行 字段名=值）而不是嵌套 JSON——小模型写单层键值对的成功率远高于嵌套 JSON。
4. **解析失败即降级，不重试三次：**直接把原文放进正文，字段留空让用户填。**用户填一个空字段的代价，远小于等待三次重试的代价。**
5. **Few-shot 示例本地化：**Prompt 里的示例必须用本县真实的作物名、乡镇名、工种名。**这是提升小模型准确率最便宜的手段，效果常常超过换更大的模型。**

(3) 上下文瘦身

措施

对话只带最近 3 轮

System Prompt 精简到 300 字以内并缓存

RAG 召回只进 3-5 条、每条截断到 150 字

长语音先做**规则化摘要**再进模型

Token 数是延迟和成本的主要驱动因素，在小模型上尤其明显（上下文越长，小模型越容易跑偏）。

(4) 稳定性兜底

- **超时预算硬约束：**抽取 3s、对话首字 2s、ASR 8s。超时即降级，不排队等待。
- **熔断：**模型 API 连续失败 5 次，熔断 60 秒，期间全走规则路径。
- **队列削峰：**所有非阻塞 AI 任务（向量化、摘要、审核）进低优队列，峰值时段允许延迟到分钟级。
- **并发闸门：**AI 调用总并发限制（如 5），超出排队。**这一个信号量能防止 AI 调用把整台低配机器的内存和连接耗尽。**

7.4 数据清洗

数据清洗在这个产品里有两个完全不同的目标，不要混在一起：**(A) 让信息对人可读；(B) 让信息对检索可用。**

(A) 入库时清洗（面向可读）

处理流水线（全部在 Worker 异步执行）：

1. **ASR 后处理**：去口语填充词（“那个”“就是说”“啊”）、去重复、加标点、数字归一化（中文数字→阿拉伯数字）、单位归一化（斤/公斤/吨统一存“斤”并保留原始单位显示）。
2. **敏感与风险处理**：风险词标记、联系方式从正文中提取到独立字段（防止爬取，也让展示可控）。
3. **归一化**：品种名/工种名映射到标准词、乡镇村名映射到区划码、价格统一为“分”存储。
4. **标题生成**：若用户未提供，用规则模板优先（{地点}{品种}{数量}{单位}{价格}），模板不成立才调模型。**规则生成的标题比小模型生成的更稳定、更信息密集。**
5. **质量打分** `quality_score`：字段完整度 + 有无图片 + 有无价格 + 正文长度合理性。用于排序和“信息不完整”提示。
6. **去重**：同作者 + 同类目 + 标题相似度 > 0.9 且 7 天内 → 提示合并而非新建（FR-PUB-10）。

关键取舍：清洗结果永不覆盖原始数据。 `raw_asr_text` 与 `body_text` 双列并存（见 6.3 规则 2）。

(B) 检索侧清洗（面向 RAG）

- **切片策略**：一条信息就是一个语义单元，**不要再切分**。县域信息普遍很短（50-200 字），切片只会破坏语义。
- **向量化文本 ≠ 展示文本**：为每条信息单独构造一段**检索专用文本**：
[招工·日结] 张家镇 装卸工 缺 3 人 日薪 180 元 管午饭 明天上工
同义: 搬运 卸货 装车 零工 短工 日结

把同义词、类目名、地名**显式写进被向量化的文本**。这比调优嵌入模型有效得多，尤其在小嵌入模型上。
- **同义词表人工维护**（FR-SCH-05）：这是全文最高杠杆的“数据工作”。一个 300 条的本地同义词表，对召回率的提升通常超过换更大的嵌入模型。
- **脏数据不入索引**：`quality_score` 过低、已过期、待审、已成交的信息**不进向量索引**。索引越小越准越快。

(C) 数据飞轮（长期最重要）

从首期就采集以下信号，它们是将来优化模型和 RAG 的唯一燃料：

用户对 AI 抽取结果的修改 diff

AI 回答的“这不对”反馈 (FR-AI-08)

搜索无结果的 query

点击了搜索结果第几位

发布后是否被联系

“用户修改 diff”这一项要特别重视：它自动积累了“模型输出 → 正确输出”的成对数据。三个月后有几千条，足以做小模型微调或构建高质量 Few-shot 池。这个数据只有现在埋点才能拿到。

7.5 RAG 优化

(1) 首期不要用独立向量数据库

信息量在数千到数万条时：

- 全量向量（1 万条 × 512 维 × 4 字节 ≈ **20MB**）可以**直接常驻应用进程内存**，暴力检索一次 < 20ms。
- 独立向量库（Milvus/Qdrant）会额外吃 500MB-1GB 内存，在 4G 机器上是净损失。

方案：向量存 MySQL (BLOB) 作为持久层，应用启动时加载进内存做暴力检索，增量更新走队列。**这是本方案里最反直觉但对低配服务器最正确的选择。**数据量超过 20 万条再考虑上 Qdrant（届时也已该升级服务器了）。

(2) 混合检索（关键词 + 向量 + 结构化过滤）

执行顺序极其重要——先过滤，后打分：

用户 query

↓

[1] 意图与条件抽取 (L0/L1, 见 7.3)

→ 类目、地域、价格区间、时间

↓

[2] 结构化硬过滤 (SQL) ★ 先做，把候选集从上万降到几百

WHERE category=? AND town_code IN (?) AND status='published'
AND valid_until > NOW()

↓

[3] 双路召回 (在几百条候选内)

├ BM25/全文匹配 → top 20

└ 向量相似度 → top 20

↓

[4] 融合 RRF (Reciprocal Rank Fusion) → top 10

↓

[5] 业务重排：距离 × 时新度 × quality_score × weight_boost

↓

[6] 取 top 3-5 进 LLM 上下文 (每条截断 150 字)

为什么必须先结构化过滤：这是低配环境下 RAG 提速的最大杠杆。在几百条候选内做向量检索，性能和精度都远好于在全量里检索再过滤。**同时它天然解决了“推荐了 50 公里外的信息”这个体验问题。**

用 RRF 而不是加权分数融合：RRF 只依赖排名不依赖分数绝对值，避免了 BM25 分数与余弦相似度不同量纲需要调参的麻烦。实现只有几行代码。

(3) 不该用 RAG 的地方

平台规则、反诈知识、帮助文档这类固定内容，不要走 RAG，直接走固定答案。

做法：维护一个 FAQ 表（问题 + 标准答案 + 同义问法），用嵌入做最近邻匹配，命中则**直接返回人工撰写的答案**，完全不过 LLM。

好处有四：零成本、零延迟、零幻觉、答案可控。**反诈提示和平台规则绝不能让模型自由生成——说错了是合规问题。**

(4) 检索质量的持续评估

建立一个 100-200 条的本地评测集（真实 query + 人工标注的正确结果），每次改动 Prompt / 换模型 / 改同义词表都跑一遍，看 Recall@5 和 MRR。**没有评测集的 RAG 优化全是玄学**，而这个评测集可以从 7.4(C) 的搜索日志里半自动构建。

7.6 前端与网络层优化

措施	说明
图片客户端压缩	上传前压缩到长边 1280px、质量 0.8（JPEG）。 县域网络上行慢（1-2 Mbps 常见），压缩可将 5MB 原图降到 300KB，上传从 20 秒降到 2 秒
图片多规格 + WebP	列表用 200px 缩略图、详情用 750px；CDN 按需转换（OSS 图片处理）
LQIP 占位	20px 模糊图内联 Base64，避免布局跳动
语音 OSS 直传	客户端签名后直传 OSS，不经应用服务器（见 4.4.2）
分包加载	小程序主包只放首页 + 逛一逛，发布/AI/我的分包，按需下载
骨架屏	首屏感知速度优化，比真实提速 300ms 更有效
客户端缓存（多层）	见下方详细策略
请求合并	首页一个接口返回轮播 + 类目 + 首屏列表，减少往返（县域弱信号 RTT 可达 500-800ms）
gzip/brotli	Nginx 开启，JSON 压缩率通常 70%+
弱网重试 + 离线草稿	县域信号不稳，发布失败必须能重试且不丢内容

客户端缓存策略（降低服务器压力的关键）

客户端缓存在县域场景有双重价值：**提速和降载**（离线可用 + 减少请求）。分三层设计：

数据类型

静态配置（类目、区划、词库、FAQ）

准静态内容（热门搜索词、同义词表）

用户草稿、历史搜索、浏览记录

列表首屏

详情页、图片

静态配置占位约 200KB，首次下载后几乎不再请求。实测效果：冷启动后二次进入，请求数从 8 个降到 2 个。

离线可用能力（首期不强制实现，但架构预留）：用户已浏览过的列表和详情，断网后仍可查看。县域信号覆盖有盲区（地下室、山区），离线缓存是体验分水岭。

“请求合并”在县域尤其重要：4G 弱信号下，单次往返 RTT 可能 300–800ms，三个串行请求就是 2 秒白屏。

7.7 服务端与数据库优化

措施

多级缓存

缓存键设计

防击穿

索引

游标分页

连接池

慢查询日志

列表字段裁剪

异步化

限流

静态化兜底

“静态化兜底”是最后一道保险：万一 DB 挂了或流量突增（比如某条信息被大量转发），首页仍能返回内容而不是 502。实现成本很低（定时任务写一个 JSON 到 OSS），但能救命。

7.8 成本控制小结

按 5.1 节的用量估算，主要成本项与压降手段：

成本项

ASR
LLM 生成
嵌入
TTS
带宽
服务器


最大的成本杠杆是“用规则替代模型”，其次是“缓存一切可缓存的模型输出”。这两条做到位，即使用最便宜的模型，单条信息服务端成本也能压到 1.5 节设定的 0.02 元以内。

八、AI 对话直取一手县域信息（场景化设计）

用户明确要求：**能在 AI 对话窗口里直接把事办成**，而不是“聊完还要自己去列表里翻”。这一章把这个要求落成可实现的机制。

8.1 核心机制：一句话 → 双向撮合

任何一句需求，AI 都同时做两件事：



这是本产品 AI 对话与通用聊天机器人的根本区别。传统搜索“查不到”就结束了；这里“查不到”是内容生产的起点。县域平台冷启动阶段供给稀薄，若只做“查”，用户十次有八次空手而归就再也不来了。“**查不到就帮你挂上去**”把每一次失败的搜索都转化为一条新的供给。

编号

FR-AI-09
FR-AI-10
FR-AI-11
FR-AI-12
FR-AI-13
FR-AI-14

FR-AI-13 的“最多一个澄清问题”是硬约束。多轮澄清在县域用户身上流失极快。缺信息宁可先出结果再让用户调整，也不要连问三句。

8.2 场景一：找球搭子（约局）

用户 "帮我找几个打球搭子"

AI 打球是打哪种？（点一下就行）
[篮球] [羽毛球] [乒乓球] [足球]
← 唯一的澄清，且可点选
用户 [羽毛球]

AI 镇上这周有 2 个羽毛球局，还缺人：

羽毛球·周六晚 19:00

城关镇全民健身馆·AA 约 15 元

还缺 2 人·中等水平

发起人 老李(发过 4 次局)

[我要报名]

羽毛球·周日上午 9:00

二中体育馆·免费

还缺 1 人·新手友好

[我要报名]

都不合适？我也可以帮你发一个局，
让别人来找你 ——
[帮我发个球局] [有新局通知我]

点「帮我发个球局」后，AI 用已知信息预填草稿（局类型=羽毛球、地点=用户所在乡镇），只留时间和缺几人待确认。用户从“找不到”到“发出一个局”只需两次点击。

8.3 场景二：木工找活（求职）

用户 "我是木工，最近没事干，帮我找下工作"

AI 好，木工的活我找了三条 ——

招木工 2 人·日结 <

张家镇装修工地·260 元/天

明天上工·管午饭

雇主 王师傅(发过 11 次·0 举报)

[查看] [我要报名]

家具厂长期招木工

城关镇·月薪 6000-8000

需会看图纸
[查看] [我要报名]

有偿任务·修木门 1 扇
李家村·悬赏 120 元·3 天内
[查看] [我接这单]

△ 任何要求先交押金、服装费、
体检费的招工都是骗局。

也可以把你的手艺挂出去，让雇主找你：
[帮我发个“木工找活”] [有木工活就通知我]

注意三个设计点：

1. **跨模块混合返回**。用户说“找工作”，系统同时命中“长期招工”“日结零工”“有偿任务”三个子类型。**这正是 3.5 统一 Post 模型带来的直接收益**——一次查询覆盖三类信息，无需三次调用。
2. **雇主行为可见**（“发过 11 次 0 举报”）替代信用分，见 FR-JOB-07。
3. **反诈提示嵌入在对话结果里**，而不是只放在详情页。招工场景是押金骗局高发区，提示必须出现在用户看到工作的那一刻（FR-ANTI-06）。

8.4 场景三：闲置农具（二手，含“帮我挂上去卖”）

用户“家里有个旧打谷机不用了，
看有没有人要，或者帮我挂上去卖”

AI 先说需求方：有 1 个人在收打谷机——

【求购】旧打谷机 1 台
王家镇·面议·能用就行
[联系他]

同时我把你这台挂出去了，你核对一下：

草稿·二手农机
标题 转让旧打谷机 能正常使用
类目 二手，农机具
价格 [] 元 ○可议价
成色 有使用痕迹 ▼
地点 你所在的镇（可改）
图片 △ 建议加 1 张，成交快很多
[加图片并发布] [直接发布]

“或者帮我挂上去卖”这句话里其实含两个意图（找买家 + 发布），AI 必须都执行，而不是选一个。这也是 FR-AI-09 双出口的意义。

价格留空而不猜价：小模型估价必然不准，猜错了会误导用户定价。留空 + 提示“可议价”比瞎猜好。图片提示写成收益导向（“成交快很多”）而不是要求导向（“请上传图片”），转化率差别很大。

8.5 实现要点

环节

意图识别

槽位抽取

检索

结果呈现

发布草稿

反诈注入

兜底

“AI 不复述事实”再强调一次：AI 负责理解“木工找活”该查什么、怎么排序、给哪些出口；日薪 260 元这个数字必须直接来自数据库字段。这条边界让小模型的幻觉风险降到近乎为零，也是本方案敢用便宜模型的底气。

九、低保真页面设计

9.1 信息架构与全局导航

底部五 tab，发布为中间凸起按钮（county 用户的核心动作必须一步可达）：



底部导航栏

(底部Tab 见首页底部) AI 对话**不占 tab**，而是在首页顶部常驻入口 + 全局右下角悬浮球。理由：AI 是手段不是目的，占 tab 会让用户误以为这是个聊天软件；悬浮球则在任何页面都能唤起。

(信息架构流程图：见各屏截图组合理解) ## 9.2 首页



设计

说明：

- 首屏第一屏必须同时出现 **AI 语音入口**和**免责/反诈条**。前者是差异化，后者是生存底线（FR-ANTI-02 精神的延伸）。
- 类目九宫格用图标 + 大字，画像 A 用户对文字列表的识别效率远低于图标。
- 列表卡片左上角的【收】【招】【局】标签用颜色区分，**一眼分辨供需方向**（FR-AGR-01）。
- 距离用“同镇”“1.2km”混合表达（FR-LOC-03）。

9.3 逛一逛（瀑布流）



设计

说明：

- 无图信息用**类目色块 + 大字标题**占位 (FR-BRW-04)。这一条很关键：县域大量信息（招工、约局）天然没有图片，如果无图就不展示，瀑布流会稀疏得无法使用。
- 已成交卡片**置灰保留而非移除** (FR-BRW-07)，‘卖出了’是最好的发布激励。
- 骨架屏而非 loading 转圈 (7.6)。

9.4 一键发布（三屏）

屏 1 — 说话（默认屏，无需选类目）



###

屏 2 — 草稿确认（AI 已填好）

返回

核对一下

发布

你说的：

00:12 我这有两百斤土鸡蛋，一块二一个，城关镇的，要的联系我...

[改字]

← 可编辑

分类 助农·农产品出售 [改]

标题 城关镇土鸡蛋 200 斤

价格 1.20 元/个

数量 200 斤 △单位对吗?

地点 城关镇 (你的位置)

有效期 15 天 ▼

联系 138****5678 ☒ 记住

图片

+

+

 加图成交快很多

← AI 判定

← 冲突高亮

← 收益导向

☒ 我承诺信息真实，不收取任何

###

前置费用		— 强制勾选
平台只提供信息交流，不担保资金		
发布 (免费)		

设计说明：

- **未识别的字段留空高亮，不弹校验弹窗**（FR-PUB-04）。图中“数量单位”冲突（斤 vs 个）用 ⚠ 提示而不阻断。
- 原始语音置顶可回听 + 可改文字，让用户确信“AI 没听错”。
- “发布(免费)”按钮文案带“免费”二字——**为将来上收费留下对比锚点**，也降低当下的心理门槛。

屏 3 — 发布成功（预期管理 + 传播）

（已合并到发布三步图中） 把“转发到微信群”做成主按钮（FR-AGR-07）：微信群是县域最强分发渠道，转化率远高于站内曝光。

9.5 AI 对话页




求职意图：AI 不只回答，还反向发布供给信息（8.3 双向撮合）



约局意图：先查存量局 → 无匹配则代拟一条，一句话即完成发布

##

9.6 详情页



详情

页的反诈条用粗框 + 固定位置 (FR-ANTI-06)：位置固定意味着老用户会形成肌肉记忆，反而不会被无视——变化的位置才会被当作广告忽略。

9.7 会话页（含反诈拦截卡）

(已合并到详情页右屏) 这是全平台反诈价值最高的一个界面 (FR-ANTI-10)。用户正处在“要不要转钱”的决策点，此刻的提示拦截率远高于任何其他位置。卡片不可关闭，且举报入口直接放在卡片上。

9.8 我的



“**键续期**”是留存的重要抓手：过期提醒推送 + 一键复活，比让用户重新发布一遍的转化率高得多，也是让 bumped_at 保持新鲜的机制。

9.9 防骗指南专页



语音版 + 三条铁律：画像 A 不读长文，只听得进「三条」
转发既是反诈也是拉新 —— 熟人网络里传播效率最高 (FR-ANTI-1.7/1.8)

版 + 可转发是这一页的关键：画像 A 用户不读长文；而“转发提醒乡亲”既是反诈也是拉新，在县域熟人网络里传播效率极高。

9.10 关键交互状态清单

低保真图之外，以下状态必须在设计阶段一并定义，**这些状态占实际开发工作量的 40% 以上：**

- 状态
- 空列表
- 加载中

弱网/失败
ASR 识别中
ASR 失败
AI 不可用
未登录
待审核
已下架
被封禁
配额用尽

十、非功能需求

类别	要求
性能	首页首屏 < 1.5s（4G）；列表接口 P95 < 300ms；AI 首字 < 1.5s；发布落库 < 500ms
可用性	核心浏览与发布链路可用性 ≥ 99.5%；AI/ASR 故障不影响发布与浏览
兼容	微信 7.0+；Android 8+ / iOS 12+；适配 320px 窄屏与老年模式大字号
无障碍	主要按钮 ≥ 44×44px；正文 ≥ 16px（老年模式 ≥ 20px）；对比度 ≥ 4.5:1；图片有 alt；语音为读写困难用户的等效替代路径
安全	HTTPS 全站；联系方式脱敏 + 访问审计；图片/语音 URL 带时效签名；接口鉴权与限流；SQL 参数化；上传文件类型与大小校验
隐私	最小必要采集；明示告知与同意；位置精度只到乡镇级存储；用户可导出与注销（数据删除）
数据留存	语音与聊天记录留存期需依合规要求确定（建议不短于 6 个月以配合纠纷与司法调取），到期自动清理
可观测	结构化日志 + 关键链路埋点；AI 调用记录（输入摘要/耗时/成本/是否降级）；核心指标看板
备份	每日全量 + binlog；每月演练一次恢复
可维护	词库/Prompt/风险词/FAQ 全部后台可改，改动不需发版

△ **隐私与数据留存条目须经律师确认**（见第○章）。语音是生物特征相关数据，其采集、存储、留存期限的合规要求高于普通文本，必须单独评估。

十一、实施路线

阶段一：MVP（约 8-10 周）

目标：验证“首次响应率 ≥ 50%”这一个假设。

周

- 1-2
- 3-4
- 4-5
- 5-6
- 6-7
- 8
- 9-10

上线前必须完成的三件非代码工作：本县作物/工种/地名词库、风险词库、反诈文案与法律文本定稿。**这三件事决定了产品能不能用，且无法靠代码弥补。**

阶段二：留存与治理（约 6-8 周）

订阅提醒与推送、分享海报、图片查重、雇主行为展示、TTS 听一听、评测集与 A/B 框架、数据飞轮看板、置顶收费能力（开关可开）。

阶段三：升级与扩张

服务器升级 + 读写分离启用、换更强模型（走 AI 网关配置切换）、向量库替换（若数据量到量级）、担保交易（**须先完成持牌机构对接与法律意见书**）、会员体系、多县多租户。

冷启动建议（业务侧，与技术同等重要）

县域双边平台的最大风险不是技术，是**空转**。建议：

- 单乡镇起步**，不要全县铺开。在一个镇做到“发了就有人应”，再复制。
- 先做供给侧的一边**：优先把 20-50 个收购商、包工头、农机手拉进来（画像 C/D），他们是需求的发起方，也是最有付费潜力的人。
- 村级信息员机制**（FR 角色表）：找 10-20 个本地能人代发信息，解决画像 A 不会用的问题。
- 前 3 个月人工兜底**：运营手动撮合、手动补全信息、手动回访。**这些人工动作产生的数据正是 7.4(C) 数据飞轮的第一批燃料。**

十二、风险与待确认清单

12.1 主要风险

风险

双边空转（有人发没人看）
诈骗事件损害口碑
赌博信息利用“打牌”类目
小模型抽取质量不达标
ASR 对方言识别率低
双端同构成本失控
低配服务器被图片流量打爆
合规要求先审后发
信息刷屏与垃圾内容

12.2 需要用户/相关方确认的开放问题

1. **县名与覆盖范围**：具体是哪个县？主要作物和主要工种是什么？（决定词库内容，直接影响 AI 效果）
 2. **合规路径**：先发后审是否可行？是否已与当地网信/市场监管部门沟通？
 3. **主体资质**：运营主体是公司还是个人？是否已有 ICP 备案与小程序类目资质？
 4. **运营人力**：前 3 个月能投入几个人做人工审核与撮合？（这直接决定先发后审是否可行）
 5. **预算量级**：服务器 + AI + 短信 + OSS 的月度预算上限是多少？（决定模型档次与 7.8 的压降力度）
 6. **技术栈偏好**：团队更熟悉 Go 还是 Node？是否已有 uni-app / Taro 经验？
 7. **语音留存期限**：能接受的语音数据留存时长？（合规与存储成本的平衡点）
 8. **收费启用时机**：预计什么时候启用置顶收费？（影响阶段二排期）
-

文档结束声明

本文档为产品需求与技术方案建议稿，**不构成法律、合规、财务或投资建议**。文中标注△的条目（合规路径、劳务关系、赌博拦截、资金担保、隐私与数据留存）必须在开发前由专业人士逐项确认。所有性能与成本数字均为工程估算，须以实际压测与账单为准。文中人名、地名、价格、电话均为示例占位，非真实数据。